

AI技术全景介绍



目录


- ◆ AI技术全景
- ◆ 硬件支撑
- ◆ 海量数据处理
- ◆ 软件平台
- ◆ 总结

AI技术全景



AI技术全景

◆ AI技术图谱



AI技术全景

◆ AI技术分类

- **硬件支撑**：需要极大的算力芯片、训练推理平台、电力资源等支撑模型的训练
- **海量数据处理**：海量的文本、视频、图片、音频的处理能力
- **软件平台**：高效率的模型训练、推理平台，保证模型训练的稳定、高效
- **算法创新**：模型结构、训练方法等的创新，从本质上提升人工智能的上限
- **行业能力**：结合各行各业的特点和技术，使得AI赋能千行百业



硬件支撑



硬件支撑

◆ 计算芯片

- **训练芯片**：高算力支持大规模模型训练（如NVIDIA A100/H100、Google TPU）
- **推理芯片**：低延迟、高能效设计（如Intel Movidius、华为昇腾、NVIDIA A10）
- **边缘AI芯片**：本地化实时处理（如Google Edge TPU、NVIDIA Jetson）
- **芯片架构**：GPU（并行计算）、ASIC（专用优化）、FPGA（可编程灵活）

硬件支撑

◆ 数据采集与输入设备

- **视觉传感器：**摄像头、LiDAR（自动驾驶/机器人）
- **语音传感器：**麦克风阵列（智能音箱/语音交互）
- **生物传感器：**医疗监测设备（如心率、血糖检测）
- **信息传输设备：**WIFI、蓝牙、5G设备



硬件支撑

◆ 存储与加速系统

- **高性能存储**：SSD、分布式存储（支持大规模数据处理）
- **内存技术**：HBM（高带宽内存）、GPU专用缓存
- **云端超算中心**：GPU集群（如NVIDIA DGX系统）
- **边缘计算平台**：集成传感器+本地处理单元（如工业物联网）

海量数据处理



海量数据处理


- ◆ 大模型训练时的数据处理是一个高度系统化的流程



数据收集与
初步处理



数据清洗与
质量过滤



数据增强与
扩展



精细化的
数据构造

海量数据处理

◆ 数据收集与初步处理

● 数据来源多元化

- ① 互联网爬取：从CommonCrawl等公开平台获取海量网页数据，包含文本、图像、音频等多模态信息
- ② 专有数据整合：融合书籍、论文、代码（如GitHub）、社交媒体对话等高质量数据，这类数据通常由企业或研究机构内部构建，非公开获取

● 初步存储与格式转换：原始数据以WARC（包含HTML元数据）、WET（纯文本提取）等格式存储，后续需转换为结构化文本以方便处理

海量数据处理

◆ 数据清洗与质量过滤

● 去重与噪声剔除

① **重复数据删除**：通过哈希算法（如MinHash、SimHash）实现文档级或段落级去重，降低冗余

② **噪声过滤**：移除广告、导航栏文本、乱码及非法内容（如色情、暴力信息），保留正文核心信息

● **语言识别与格式统一**：使用FastText等工具识别文本语言，并过滤非目标语言内容；统一文本编码（如UTF-8）、段落分隔符等，确保后续处理一致性

● **质量评分与过滤**：计算文本困惑度（Perplexity），剔除低质量段落；构建分类模型，区分文本质量，保留高可信度数据

海量数据处理

◆ 数据增强与扩展

● 图像数据增强

- ① 几何变换：旋转、裁剪、翻转（如水平/垂直翻转）
- ② 噪声注入：添加高斯噪声等，提升模型鲁棒性

● 文本数据增强

- ① 同义词替换：利用WordNet或大语言模型（LLM）生成语义一致的替代词
- ② 句子重构：随机删除、插入或交换词序，生成多样化表达

● 多模态数据融合：结合图像生成（如扩散模型）与文本描述增强，生成图文配对数据，提升跨模态学习能力

海量数据处理

◆ 精细化的数据构造

- 有监督多任务数据构造

- ① 数学任务数据
- ② 代码任务数据等

- 逻辑推理数据构造

- ① COT数据
- ② 逻辑推理数据


- 人类反馈式强化学习数据构造

- ① 奖励模型数据
- ② 强化学习数据

软件平台

软件平台

◆ 大模型训练阶段核心框架



基础训练框架



分布式训练优化工具



参数高效微调工具

软件平台

◆ 基础训练框架

- **PyTorch**: 动态图机制便于调试, 支持分布式训练和混合精度计算, 与Hugging Face生态深度集成。适用于快速原型设计和研究项目
- **TensorFlow**: 静态图优化适合生产环境, 提供TFX全流程管理工具 (数据验证、分布式训练、模型服务化)
- **PaddlePaddle**: 全国产模型训练、推理框架
- **MindSpore**: 华为基于其硬件生态研发的框架, 兼容pytorch

软件平台

◆ 分布式训练优化工具

- **DeepSpeed**: 微软开发的分布式训练库, 支持ZeRO显存优化、3D并行 (数据/模型/流水线并行), 千亿级参数训练效率提升40%
- **Megatron-LM**: NVIDIA的分布式训练框架, 针对Transformer模型优化张量并行策略, 支持万亿参数模型训练
- **Colossal-AI**: 提供异构并行策略和显存优化技术, 支持MoE (专家混合) 模型训练


软件平台

◆ 参数高效微调工具

- **PEFT**: Hugging Face开发的参数高效微调库, 支持LoRA、QLoRA等低秩适配技术, 仅调整0.1%参数即可实现接近全参数微调效果
- **Axolotl**: 提供YAML配置驱动的微调流程, 支持全模型微调、LoRA和QLoRA, 简化多任务训练管理
- **LLaMA-Factory**: 支持100+模型的统一微调平台, 提供CLI和Web UI两种操作界面

软件平台


◆ 大模型部署阶段主流工具



一站式部署平台



推理加速框架



边缘计算与硬件优化

软件平台

◆ 一站式部署平台

- **Ollama**: 支持1700+预训练模型的本地化部署, 跨平台兼容性优秀, 单命令启动适合个人开发者测试
- **LMDeploy**: 零一万物开发的低延迟推理引擎, TTFT (首包延迟) 低于100ms, 支持W4A16量化显存占用减少60%
- **Ray Serve**: 支持分布式模型服务, 动态扩缩容和框架无关特性适合企业级生产环境

软件平台

◆ 推理加速框架

- **vLLM**: 采用PagedAttention技术实现96%显存利用率，吞吐量较原生Transformer提升24倍，适合高并发在线服务
- **TensorRT-LLM**: NVIDIA推出的推理优化引擎，支持多GPU张量并行，在A100上推理速度提升3倍
- **DeepSpeed-MII**: 微软的分布式推理框架，支持ZeRO-Inference显存分区技术，适合超大规模模型部署

软件平台

◆ 边缘计算与硬件优化

- **NVIDIA Triton**: 支持多框架模型（TensorFlow/PyTorch/ONNX）的统一推理服务，适用于边缘设备部署
- **OpenVINO**: Intel开发的视觉模型优化工具，通过神经网络压缩和硬件指令集加速边缘推理
- **MindSpore Serving**: 华为昇腾芯片专用部署工具，支持动态批处理和NPU加速，国产化替代方案代表

软件平台

◆ 大模型应用开发框架

- **Dify**: 支持可视化编排AI workflow, 集成RAG引擎、Agent管理和模型监控功能, 提供API接口快速对接业务系统, 适合从原型到生产的全生命周期管理
- **LangChain**: 支持链式调用、智能体、记忆管理三大核心模块, 集成200+外部服务接口和向量数据库, 通过LCEL表达式语言实现复杂逻辑编排
- **Rankify**: Rankify 是一款由因斯布鲁克大学研究团队开发的 Python 工具包, 旨在统一信息检索、重排序和检索增强生成三大关键流程

总结



总结

- **复杂性：**人工智能行业的发展对半导体芯片、工程师能力要求极高
- **交叉性：**涉及数学、计算机硬件、计算机软件、数据工程等多门学科，高度交叉
- **算法工程师：**集中精力pytorch、DeepSpeed、vLLM等训练推理框架的熟悉上即可
- **应用工程师：**集中精力在vLLM、langchain等应用框架的熟悉即可

下次预告：正式开始学习了